

# Предсказание пола пользователей соцсетей

ML-проект по бинарной классификации  
пользователей на основе рекламных событий



# Бизнес-контекст

VK Реклама заинтересована в **повышении эффективности рекламного таргетинга**.

Более точное определение характеристик аудитории может помочь:

- показывать рекламу более **релевантным** пользователям
- снижать долю нецелевых показов
- **эффективнее** расходовать рекламный бюджет
- **повышать CTR и конверсию** рекламных кампаний
- улучшать **качество** рекламных продуктов VK



## VK Реклама



**Потенциальный внешний клиент** - компания, продающая подарочные наборы и планирующая запуск рекламной кампании перед праздничным периодом

**Ключевая идея:** модель может стать дополнительным инструментом сегментации аудитории

# ML-постановка задачи

**Тип задачи:**  
бинарная  
классификация

**Целевая  
переменная:**



target = пол  
пользователя

**target = 0** - один  
закодированный  
класс пола

**target = 1** - другой  
закодированный  
класс пола

**Итоговый объект  
предсказания:**

user\_id - конкретный  
пользователь  
социальной сети

**Особенность задачи:**


исходные данные находятся на уровне рекламных событий, но предсказание нужно делать на уровне пользователя

# Данные проекта

В проекте использовались несколько **источников данных**:

- [train.csv](#) - рекламные события обучающей выборки
- [train\\_labels.csv](#) - целевая переменная на уровне пользователя
- [test.csv](#) - рекламные события тестовой выборки
- [test\\_users.csv](#) - пользователи для финального предсказания
- [referrer\\_vectors.csv](#) - числовые URL-векторы
- [geo\\_info.csv](#) - географическая информация

## Основные признаки



# Общий пайплайн проекта

## Входная информация

Бизнес-контекст + ML-постановка задачи + источники данных

## Первичный анализ данных

Структура данных, размеры, пропуски, дубликаты, кардинальность

## Предобработка данных

Удалены дубликаты, обработаны пропуски, преобразован timestamp, выполнено объединение таблиц

## Разведочный анализ данных

Распределения признаков, структура target, география, временные паттерны, user-agent и referer

## Обучение более сложных моделей

RandomForestClassifier  
LGBMClassifier  
CatBoostClassifier

## Обучение baseline моделей

DummyClassifier  
LogisticRegression

## Подготовка выборок

Данные разделены на train и valid с сохранением баланса классов.  
Выбраны метрики ROC-AUC, accuracy и F1-score

## Feature engineering

- агрегация событий
- счетчики, уникальные значения
- категориальные признаки
- временные признаки
- агрегаты URL

## Подбор гиперпараметров лучшей модели

Для CatBoost выполнен Grid Search по ключевым параметрам

## Обучение финальной модели на всех обучающих данных

CatBoostClassifier grid tuned

## Формирование предсказаний для тестовых пользователей

Модель обучена на всех размеченных данных и использована для submission

## Результат


лучшая модель:  
CatBoostClassifier grid tuned  
  
дополнительный сигнал для рекламной сегментации

# Результаты разведочного анализа данных EDA


## Ключевые наблюдения

- целевая переменная достаточно **сбалансирована**
- у большинства пользователей наблюдается **только 1 рекламное событие**
- пик активности приходится на дневные и вечерние часы


Распределение рекламных событий по часам



Распределение количества событий на пользователя






Распределение целевой переменной



# Результаты разведочного анализа данных EDA

## Ключевые наблюдения: категориальные признаки и связь с target



- **referer\_domain** дает самый сильный категориальный сигнал
- разные **браузеры** показывают различия в доле target=0 и target=1
- **географические** признаки (country\_id, region\_id, timezone\_id) тоже содержат полезный сигнал



# Результаты разведочного анализа данных EDA

## Ключевые наблюдения: URL-компоненты как числовой сигнал

- URL-компоненты действительно **различаются между классами**
- часть компонент смещена в сторону  $\text{target}=1$ , часть в сторону  $\text{target}=0$
- корреляции между компонентами в основном **умеренные**, то есть признаки не полностью дублируют друг друга





# Feature engineering

## Агрегация до уровня user\_id

Исходные данные были представлены на уровне рекламных событий

*1 строка = 1 рекламное событие*

НО target задана на уровне пользователя

*1 строка = 1 user\_id*

Поэтому перед обучением модели события были агрегированы до уровня пользователя

*train\_full / test\_full (рекламные события)*  
↓  
*groupby(user\_id)*  
↓  
*агрегация признаков*  
↓  
*train\_user\_features / test\_user\_features*  
*1 строка = 1 пользователь*

## train\_user\_features

**500 000**  
пользователей

**57 колонок**

## X для модели

**500 000**  
пользователей

**55 признаков**

**активность + география + user-agent +**  
**URL-векторы**

**6**  
категориальных  
признаков

**49 числовых**  
признаков

# Feature engineering

Какие признаки были добавлены

| Группа признаков        | Примеры                                                         | Смысл                                 |
|-------------------------|-----------------------------------------------------------------|---------------------------------------|
| <u>Активность</u>       | events_count                                                    | сколько событий было у пользователя   |
| <u>Разнообразие URL</u> | unique_referer_count, unique_referer_domain_count               | насколько разнообразны сайты и домены |
| <u>География</u>        | unique_geo_id_count, unique_country_count, unique_region_count  | географическое разнообразие           |
| <u>Время</u>            | first_request_hour, last_request_hour                           | время активности пользователя         |
| <u>Категории</u>        | country_id, region_id, timezone_id, referer_domain, browser, os | основные характеристики пользователя  |
| <u>URL-векторы</u>      | mean, std, min, max по component0-component9                    | числовое описание посещенных URL      |

# Обучение моделей

X - признаки пользователя  
y - target

train: 80%  
valid: 20%

стратификация по target

Основная метрика:

ROC-AUC

Дополнительные  
метрики:

- accuracy
- F1-score


Для сравнения были обучены модели разной сложности

| Модель                        | Роль в проекте                                |
|-------------------------------|-----------------------------------------------|
| <b>DummyClassifier</b>        | случайный baseline                            |
| <b>LogisticRegression</b>     | простой линейный baseline                     |
| <b>RandomForestClassifier</b> | ансамбль решающих деревьев                    |
| <b>LGBMClassifier</b>         | градиентный бустинг                           |
| <b>CatBoostClassifier</b>     | бустинг с поддержкой категориальных признаков |
| <b>CatBoost grid tuned</b>    | CatBoost после подбора гиперпараметров        |

# Сравнение качества моделей

| Модель                 | ROC-AUC | Accuracy | F1     |
|------------------------|---------|----------|--------|
| CatBoost grid tuned    | 0.9341  | 0.8770   | 0.8702 |
| CatBoostClassifier     | 0.9276  | 0.8699   | 0.8628 |
| LGBMClassifier         | 0.9128  | 0.8512   | 0.8431 |
| LogisticRegression     | 0.8566  | 0.7929   | 0.7773 |
| RandomForestClassifier | 0.8357  | 0.7659   | 0.7423 |
| DummyClassifier        | 0.5017  | 0.5028   | 0.4788 |

# Сравнение качества моделей



# Выбор финальной модели

## Подбор гиперпараметров лучшей модели с помощью Grid Search



CatBoost до tuning: ROC-AUC = 0.9276

**CatBoost после tuning: ROC-AUC = 0.9341**

depth = 7

learning\_rate = 0.12

l2\_leaf\_reg = 3



# Бизнес-выводы

**Бизнес-цель проекта** - повысить эффективность рекламного таргетинга за счёт автоматического определения пола пользователей.

Построенная модель может использоваться как **дополнительный сигнал для сегментации аудитории**.

**Потенциальная польза:**

- более точный таргетинг
- повышение релевантности рекламных показов
- снижение доли нецелевых показов
- более эффективное расходование рекламного бюджета
- улучшение качества рекламных кампаний



**VK Реклама**

# Ограничения и дальнейшие шаги

## Ограничения:

- данные покрывают короткий временной период (сутки)
- большинство пользователей имеют только одно событие
- классы 0 и 1 закодированы
- качество проверялось на валидационной выборке
- реальный бизнес-эффект требует A/B-теста

## Рекомендации:

- проверить модель на данных другого периода
- использовать вероятности модели как скоринг
- подобрать порог под бизнес-цель
- добавить новые признаки из браузера, ОС и referer
- настроить мониторинг
- проверить эффект через A/B-тест



# Итог проекта

**В проекте был построен полный ML-пайплайн для предсказания пола пользователей на уровне user\_id.**

## Что сделано:

- проведен первичный и разведочный анализ данных
- выполнена предобработка
- данные агрегированы до уровня пользователя
- обучены и сравнены несколько моделей
- выполнен Grid Search для CatBoost
- выбрана финальная модель
- сформирован submission.csv с предсказаниями

## Финальный результат:

### CatBoostClassifier grid tuned

- ROC-AUC = 0.9341
- accuracy = 0.8770
- F1-score = 0.8702

